





# 데이터 정제 파이프라인

AI 모델의 운명을 결정하는 데이터 전처리의 모든 것



# AI의 절대 법칙



## Garbage In, Garbage Out

쓰레기 데이터를 넣으면 쓰레기 결과가 나온다. AI의 성능은 오직 입력된 데이터의 품질에 종속됩니다.

# 좋은 학습 데이터를 규정하는 5가지 조건



## Volume (양)

수만에서 수백만  
건에 이르는 충분한  
데이터 규모



## Diversity (다양성)

특정 집단에  
치우치지 않은  
고른 분포



## Accuracy (정확성)

정답과 완벽하게  
일치하는  
레이블(Label)



## Recency (최신성)

과거가 아닌  
현재의 현실을  
반영하는 정보



## Unbiased (편향 없음)

특정 인종, 성별,  
연령에 대한  
차별 배제




# 원칙을 무시한 AI의 현실

| 사건                   | 문제                                          | 위반 조건                                                                                                       |
|----------------------|---------------------------------------------|-------------------------------------------------------------------------------------------------------------|
| 아마존(Amazon)<br>채용 AI | 남성 이력서 위주 학습<br>→ 여성 지원자 자동 탈락              |  Unbiased<br>(편향 없음) 결여  |
| 안면 인식<br>AI 알고리즘     | 밝은 피부 사진 위주 학습<br>→ 어두운 피부 인식 실패            |  Diversity<br>(다양성) 결여 |
| 초기 의료 진단 AI          | 과거의 낡은 의료 기록 학습<br>→ 현재의 새로운 질병 패턴<br>진단 불가 |  Recency<br>(최신성) 결여   |




# 완벽한 데이터를 향한 4단계 파이프라인





# 1단계: Cleaning (정제)


오류, 중복 데이터, 그리고 비어있는 결측값을 제거하여 데이터의 기초 체력을 확보합니다.






## 2단계: Transformation (변환)

AI가 연산할 수 있도록 텍스트 문자를 숫자로 변환하고, 데이터의 스케일을 맞추는 정규화(Normalization) 작업을 수행합니다.



## 3단계: Split (분할)


데이터를 학습, 검증, 테스트 목적으로 체계적으로 분할하여  
모델의 성능을 정확하게 평가합니다.





# 4단계: Augmentation (증강)

수집된 데이터가 부족할 때, 기존 데이터를 의도적으로 변형(회전, 확대, 반전)하여 학습량을 인위적으로 폭발시킵니다.





# AI의 성능은 결국 데이터가 결정합니다



## 품질의 최우선 (Quality First)

알고리즘보다 데이터의 퀄리티가 결과의 한계선을 정합니다.

### [전처리 파이프라인 (4단계)]



## 편향의 위험성 (Danger of Bias)

편향된 데이터는 곧 차별하는 AI를 낳습니다.



## 파이프라인의 힘 (The Power of Pipeline)

정제(Cleaning), 변환(Transformation), 분할(Split), 증강(Augmentation)의 파이프라인이 AI 프로젝트의 성공을 좌우합니다.