




AI 모델의 두 가지 함정: 과적합과 편향

수학적 오류에서 윤리적 실패까지 (From Mathematical Errors to Ethical Failures)

코딩 교육 학원 AI 심화 과정

기술적 영점 조절 (Technical Calibration)



과적합(**Overfitting**)의 개념과 원인,
그리고 해결책을 진단합니다.

윤리적 영점 조절 (Ethical Calibration)



실제 사례를 통해 **AI 편향(Bias)**이
현실 세계에 미치는 영향을 분석합니다.



과소적합
(Underfitting)



최적합
(Optimal Fit)




과적합
(Overfitting)

AI 학습의 목표는 단순히 '많이' 배우는 것이 아니라,
새로운 데이터에 대응할 수 있는 '일반화(Generalization)' 능력을 갖추는 것입니다.



비유: 공부를 너무 적게 한 학생 (The unprepared student)




모델이 너무 단순하여 데이터의 패턴 자체를 파악하지 못함.



과소적합 (Underfitting): 학습 데이터와 새로운 데이터 모두에서 실패.



비유: 원리를 완벽히 이해한 학생 (The student who grasps the principles)




데이터의 '일반적인 패턴'을 성공적으로 학습함.



최적합 (Optimal Fit): 새로운 응용 데이터(Unseen Data)에서도 높은 성능 발휘.



비유: 시험 답만 달달 외운 학생
(The student who memorized the answers)



학습 데이터에 '너무 잘 맞춰서' 노이즈(Noise)까지 암기함.



과적합 (Overfitting): 학습 데이터는 100% 맞추지만, 새로운 데이터에서는 완벽히 실패.

과소적합 (Underfitting)

과적합 (Overfitting)

증상
(Symptom)

패턴 파악 실패
(Fails to capture patterns)

노이즈까지 암기
(Memorizes noise)


원인
(Causes)

모델이 너무 단순함
(Model too simple),
학습 부족

데이터 부족 (Data shortage),
모델이 너무 복잡함
(Model too complex)

해결책
(Solutions)

→ → →
더 복잡한 모델 사용,
더 많은 학습 시간 확보




더 많은 데이터 확보,
정규화 (Regularization),
드롭아웃 (Dropout) 도입



완벽한 수학, 하지만 망가진 데이터?

모델이 수학적으로 완벽하게 최적합(Optimal Fit)을 이루었더라도, 학습하는 '데이터 자체'가 편향되어 있다면 어떻게 될까요?

수학적 최적합 (Optimal Mathematical Fit)




손상된 데이터 입력 (Corrupted Real-World Input)



**알고리즘의 문제가 아닙니다.
데이터의 문제입니다.**

AI 편향의 증폭 (Amplification of AI Bias)

입력 (Input)



역사적, 사회적 편향이
담긴 학습 데이터



AI 블랙박스
(AI Model)

패턴을 충실히 학습함



AI 편향 (Bias)




데이터의 차별이 AI 결과에
그대로 증폭되어 반영됨

실제 사례 1: 아마존 채용 AI (Amazon Hiring AI)



과거 10년간의 이력서
(대부분 남성)



남성 중심의 패턴을
'우수함'으로 인식




'여성' 관련 단어가 포함된
이력서 자동 감점 및 차별

실제 사례 2: 얼굴 인식 AI (Facial Recognition AI)



입력 데이터
백인 위주로 구성된
이미지 학습 데이터




AI 학습
특정 인종의 안면 특징에만
과적합(Overfitting)



결과
유색인종에 대한 심각한
인식률 저하 및 오류 발생

실제 사례 3: 범죄 예측 AI (Crime Prediction AI)



AI 공정성 (Fairness) = 데이터 공정성 (Data Fairness)

기술적 오류와 윤리적 실패는 모두 '데이터'라는 같은 뿌리에서 시작됩니다.





과적합 (Overfitting)

학습 데이터만 잘 맞추고
실전(New Data)에서는
완벽히 실패하는
기술적 함정.



편향 (Bias)

인간이 만든 데이터의
차별과 편견이
AI 알고리즘을 통해
그대로 복제되는 현상.



핵심 원칙 (Core Principle)

AI의 기술적 완벽함과
윤리적 공정성은 오직
'데이터의 공정성'에서
시작된다.