


LLM은 어떻게 말할까?

인공지능의 사고 과정을 해부하는 청사진

PRECISION TARGETING:
NEXT TOKEN PREDICTION




학습 목표

LLM의 작동 원리인 Next Token Prediction 메커니즘을 완벽히 이해한다.


- ☐ 언어 모델의 텍스트 생성 과정 분해
- ☐ Hallucination(환각)의 구조적 원인 파악
- ☐ 파라미터(Temperature) 제어 방법 습득

LLM = Large Language Model



LLM의 단 하나의 핵심 원리

“문장을 이해하는 것이 아니라,
다음에 올 가능성이 가장
높은 단어를 **예측**하는 것.”



텍스트의 해체: Token




LLM은 단어가 아닌, 컴퓨터가 계산할 수 있는 조각인 Token 단위로 텍스트를 인식합니다.

Step 1. Input Analysis




오늘 날씨가 정말




LLM
(Neural Network)

사용자의 프롬프트가 Token으로 변환되어 모델 내부의 연산 파이프라인으로 진입합니다.

Step 2. Probability Calculation




Step 3. Next Token Prediction




입력된 문맥 뒤에 이어질 모든 가능성 중,
가장 수학적 확률이 높은 후보군을 정렬합니다.

Step 4. Selection & Output



모델의 설정값에 따라 가장 적합한 Token이 최종 선택되어 화면에 출력됩니다.

Step 5. Auto-regressive Loop



생성된 단어는 다시 입력 프롬프트의 끝에 붙어 새로운 예측의 기준이 됩니다.
이 과정이 무한 반복되며 문장이 완성됩니다.

The LLM Pipeline



Next Token Prediction의 끊임없는 순환 구조.

Pattern Matching vs Understanding



진정한 이해 (Understanding)

- 논리적 추론
- 문맥적 사실 확인
- 의미의 파악




패턴 매칭 (Pattern Matching)

- 통계적 확률 계산
- 다음 토큰의 배치
- 데이터 모방

LLM은 텍스트의 '의미'를 아는 것이 아니라, 글자의 '통계적 배치 패턴'을 모방할 뿐입니다.

The Side Effect: Hallucination

AI가 그럴듯하지만 완전히 틀린 정보를 사실처럼 생성하는 현상.



이해가 결여된 확률적 텍스트 생성의 필연적 부작용.

왜 환각(Hallucination)이 발생할까?

질문: 존재하지 않는 역사적 사건

Truth/Fact Check ✕

모릅니다

확률이 낮아
무시됨


✓ Probability

1920년에
발생한...

문법적으로 연결될
확률이 높아 선택됨

LLM은 '진실'보다 '문법적으로 가장 자연스러운 확률'을 우선순위로 둡니다.

Parameter: Temperature



Temperature는 다음 토큰을 선택할 때의 '랜덤성'을 조절하는 핵심 파라미터입니다.

Temperature 0 vs 1

Temperature = 0



무조건 1위 토큰만 선택.
항상 동일하고 정확한 답변.
(코드 작성, 데이터 분석에 적합)

Temperature = 1



다양한 토큰을 허용.
매번 다른 창의적인 답변.
(아이디어 브레인스토밍, 소설 작성에 적합)

Code Example: Temperature 제어

```
import openai

response = openai.chat.completions.create(
    model="gpt-4o",
    messages=[{"role": "user", "content": "오늘 날씨가 정말"}],
    temperature=0.7,
    max_tokens=50
)
```

창의성과 정확성의 밸런스 조정

개발자는 API 호출 시 이 파라미터들을 조작하여 AI의 대답 성향을 애플리케이션의 목적에 맞게 튜닝합니다.

The LLM Ecosystem




동일한 Next Token Prediction 원리를 사용하지만,
학습 데이터와 튜닝 방식에 따라 각 모델은 고유한 특성을 갖습니다.

Major Models Comparison Matrix

모델	회사	핵심 강점	
GPT-4o	OpenAI	멀티모달, 가장 빠른 속도	
Claude 4	Anthropic	뛰어난 안전성, 긴 문맥 처리, 우수한 코딩 능력	
Gemini 2.5	Google	강력한 검색 엔진 통합, 네이티브 멀티모달	
Llama 4	Meta	누구나 활용 가능한 강력한 오픈소스 생태계	

Quick Check

Q. LLM의 핵심 작동 원리는 문장의 의미를 완벽히 이해하는 것이다?



정답: Next Token Prediction을 통한 확률적 예측

Q. AI가 그럴듯한 거짓말을 만들어내는 현상을 무엇이라 하는가?

Hallucination

Key Takeaways



확률적 예측 모델

LLM은 가장 수학적 확률이 높은 다음 Token을 끊임없이 예측하는 엔진이다.



패턴 매칭과 한계

진정한 이해가 아닌 패턴 매칭의 결과물이며, 이로 인해 Hallucination(환각)이 발생한다.



다양한 생태계 경쟁

GPT, Claude, Gemini, Llama 등 각자의 특징점을 가진 모델들이 생태계를 주도하고 있다.