


개발자를 위한 AI 텍스트 처리 구조, API 비용, 그리고 성능의 상관관계

 NotebookLM

Token = AI가 텍스트를 인식하고 쪼개는 최소 단위



단어나 글자 수가 아닌, AI 모델이 학습한 고유의 분절 규칙을 따릅니다.


학습 목표 1:

Token의 기본 개념을 정확히 이해한다.

학습 목표 2:

Token 수가 시스템의 비용과 성능에 미치는 영향을 파악한다.

언어별 구조적 비대칭성: 한국어 처리의 높은 비용



영어 기준

1단어 $\approx$ 1~1.5 Token

Hello



Hello

결과: 1 Token

한국어 기준

1글자 $\approx$ 2~3 Token

안녕하세요



안녕

하세

요


결과: 3 Token

한국어가 더 비쌘!

Token이 시스템에 미치는 3가지 핵심 영향

제한. 한 번에 입력하고
처리할 수 있는
절대적 한계치.

Context Window



비용. API는 처리된 Token 수에
비례하여 과금됩니다.

GPT-4 기준 입력 1000 Token $\approx$ 30원

속도. 연산해야 할
Token이 많아질수록
응답 시간(Latency)은
느려집니다.

주요 AI 모델의 Context Window 처리 용량 비교



개발자가 기억해야 할 **Token** 아키텍처 3대 원칙

The Primitive



처리 최소 단위

Token은 글자나 단어가 아닌 AI의 고유한 텍스트 처리 단위입니다.

The Variable



한국어 페널티

영어보다 한국어 처리 시 더 많은 Token이 발생하여 비용 구조가 달라집니다.

The Trilemma



성능의 3요소

Token의 양은 API 비용, 응답 속도, 그리고 Context Window 제한을 결정합니다.